Лаб 1

Предварительная обработка текстовых данных

4 ИВТ_ТИИ Клименко В.А.

```
import re
import os
import glob
import pandas as pd
import matplotlib.pyplot as plt

from nltk.tokenize import sent_tokenize, word_tokenize
from nltk.corpus import stopwords
from nltk.stem import SnowballStemmer

import spacy
import pymorphy3

from wordcloud import WordCloud

nlp_spacy = spacy.load("ru_core_news_sm")
morph = pymorphy3.MorphAnalyzer()
stop_words = set(stopwords.words('russian'))

DATA_PATH = "../lab1_data/raw_texts/"

texts = []
file_names = []

for file_path in sorted(glob.glob(os.path.join(DATA_PATH, "*.txt"))):
    with open(file_path, "r", encoding="utf-8") as f:
        texts.append(f.read())
    file_names.append(os.path.basename(file_path))

print(f"Загружено файлов: {len(texts)}")
print(f"Пример первого файла ({file_names[0]}):\n{texts[0][:200]}")
```

```
Загружено файлов: 15
Пример первого файла (news_01_tech.txt):
Компания Apple официально представила новый смартфон iPhone 15 Pro.
По словам генерального директора Тима Кука, устройство получило титановый корпус
и улучшенную камеру на 48 мегапикселей. Стоимость
```

```
texts_lower = [t.lower() for t in texts]

print("БЫЛО:", texts[0][:80])
print("СТАЛО:", texts_lower[0][:80])
```

```
БЫЛО: Компания Apple официально представила новый смартфон iPhone 15 Pro.
По словам г
СТАЛО: компания apple официально представила новый смартфон iphone 15 pro.
по словам г
```

```
texts_clean = []

for text in texts_lower:
    texts_clean.append(re.sub(r'[^а-яёa-z\s]', '', text))

print("БЫЛО:", texts_lower[0][:80])
print("СТАЛО:", texts_clean[0][:80])
```

```
БЫЛО: компания apple официально представила новый смартфон iphone 15 pro.
по словам г
СТАЛО: компания apple официально представила новый смартфон iphone  pro
по словам гене
```

```
sentences_all = [sent_tokenize(t, language='russian') for t in texts_clean]
tokens_all = []

for sentences in sentences_all:
    tokens = []
    for sentence in sentences:
        tokens.extend(word_tokenize(sentence, language='russian'))
    tokens_all.append(tokens)

print(f"Всего предложений: {sum(len(s) for s in sentences_all)}")
print(f"Всего токенов: {sum(len(t) for t in tokens_all)}")
print(f"Пример токенов первого документа: {tokens_all[0][:15]}")
```

```
Всего предложений: 15
Всего токенов: 667
Пример токенов первого документа: ['компания', 'apple', 'официально', 'представила',
'новый', 'смартфон', 'iphone', 'pro', 'по', 'словам', 'генерального', 'директора',
'тима', 'кука', 'устройство']
```

```
tokens_no_stop = []

for tokens in tokens_all:
    filtered_tokens = [w for w in tokens if w not in stop_words and len(w) > 2]
    tokens_no_stop.append(filtered_tokens)

before = sum(len(t) for t in tokens_all)
after = sum(len(t) for t in tokens_no_stop)

print(f"Токенов до удаления стоп-слов: {before}")
print(f"Токенов после: {after}")
print(f"Удалено: {100 * (before - after) / before:.1f}%")
```

```
Токенов до удаления стоп-слов: 667
Токенов после: 499
Удалено: 25.2%
```

```python
def lemmatize_pymorphy(tokens):
    return [morph.parse(word)[0].normal_form for word in tokens]


stemmer = SnowballStemmer("russian")


def stem_words(tokens):
    return [stemmer.stem(word) for word in tokens]


lemmas_all = [lemmatize_pymorphy(t) for t in tokens_no_stop]
stems_all = [stem_words(t) for t in tokens_no_stop]

comparison = pd.DataFrame({
    'Исходное': tokens_no_stop[0][:10],
    'Лемма': lemmas_all[0][:10],
    'Стем': stems_all[0][:10]
})
print(comparison.to_string(index=False))
```

```
    Исходное       Лемма      Стем
    компания    компания    компан
       apple       apple     apple
 официально  официально официальн
представила представить  представ
       новый       новый       нов
    смартфон    смартфон  смартфон
      iphone      iphone    iphone
         pro         pro       pro
      словам       слово      слов
генерального генеральный генеральн
```

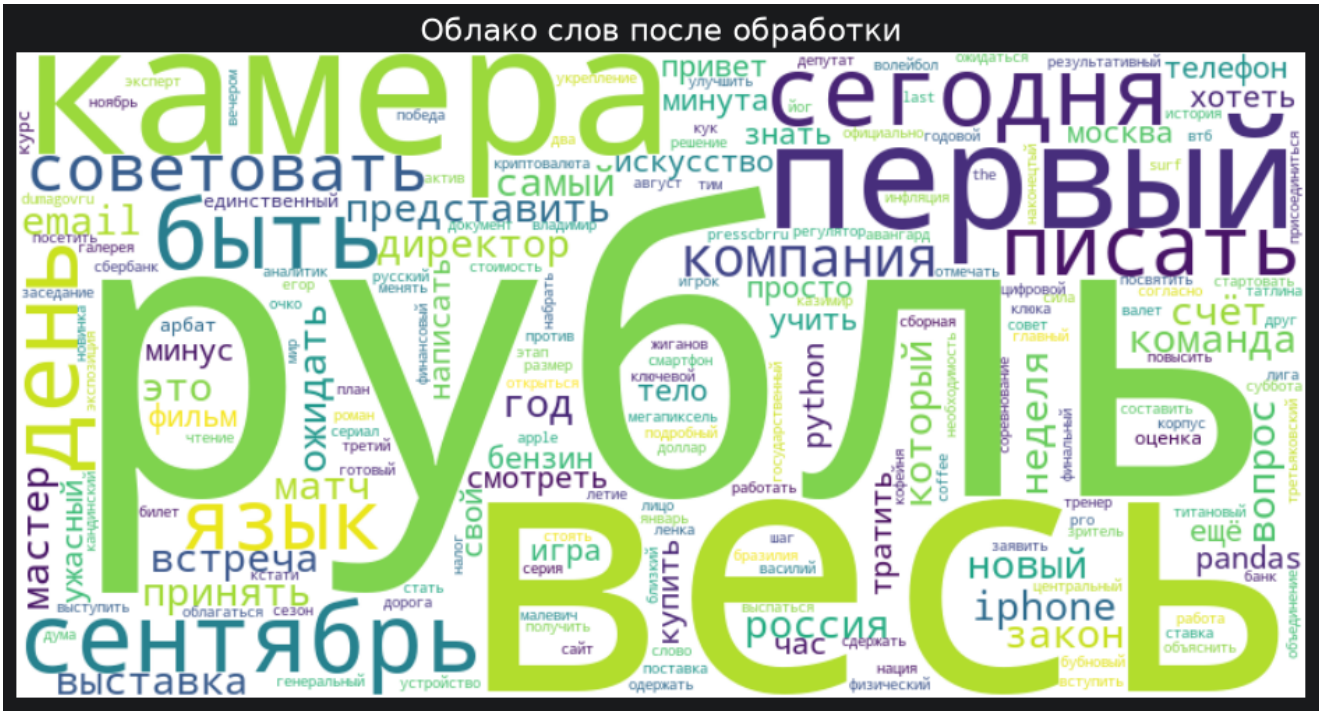
```python
from collections import Counter

all_lemmas = [w for doc in lemmas_all for w in doc]
freq = Counter(all_lemmas)

top20 = freq.most_common(20)
print("Топ-20 лемм:")
for word, count in top20:
    print(f" {word}: {count}")

wc = WordCloud(
    width=800,
    height=400,
    background_color='white',
    colormap='viridis',
).generate_from_frequencies(freq)
plt.figure(figsize=(12, 6))
plt.imshow(wc, interpolation='bilinear')
plt.axis('off')
plt.title('Облако слов после обработки', fontsize=16)
plt.savefig('../wordcloud_after.png', dpi=150, bbox_inches='tight')
plt.show()
```

```
Топ-20 лемм:
 рубль: 5
 весь: 4
 камера: 3
 первый: 3
 сентябрь: 3
 быть: 3
 сегодня: 3
 день: 3
 писать: 3
 язык: 3
 советовать: 3
 компания: 2
 представить: 2
 новый: 2
 iphone: 2
 директор: 2
 россия: 2
 год: 2
 это: 2
 самый: 2
```


Облако слов после обработки
камера
рубль
весь
первый
сегодня
писать
сентябрь
день
быть
советовать
привет
минута
знать
искусство
самый
представить
директор
компания
просто
учить
python
который
неделя
вопрос
счёт
команда
тело
год
ожидать
матч
язык
встреча
принять
выставка
бензин
смотреть
игра
купить
тратить
новый
iphone
закон
россия
час
pandas
ещё
телефон
хотеть
москва
email
дмитрий
ноябрь
курс
эксперт
вечером
победа
два
криптовалюта
август
тим
йог
last
официально
годовой
втб
the
surf
инфляция
наконецтый
присоединиться
дumagovru
единственный
посетить
галерея
сбербанк
аналитик
егор
русский
менять
финансовый
написать
набрать
стоимость
документ
владимир
presscbrru
регулятор
авангард
отмечать
игрок
цифровой
клюка
совет
главный
сборная
казимир
посвятить
согласно
стартовать
татлина
валет
друг
повысить
лига
суббота
третьяковский
составить
корпус
оценка
финальный
соревнование
необходимость
coffee
кофейня
государственный
работать
тренер
зритель
pro
титановый
заявить
центральный
банк
работа
ставка
объяснить
бубновый
вступить
объединение
заседание
экспозиция
новинка
арбат
минус
это
фильм
чтение
мир
очко
план
роман
сериал
третий
готовый
каприйский
мастер
ужасный
билет
кстати
выступить
облагаться
сезон
дума
стать
дорога
генеральный
устройство
свой
налог
стоять
летие
лицо
январь
ленка
шаг
бразилия
василий
серия
близкий
малевич
получить
сайт
слово
поставка
одержать
нация
физический
выспаться
сдержать
апple
против
этап
размер
открыться
ключевой
жиганов
смартфон
мегапиксель
подробный
доллар
укрепление
улучшить
решение
кук
актив
документ
владимир
the
surf
инфляция
наконецтый
присоединиться

```
raw_text = ' '.join(texts).lower()

raw_words = re.findall(r'[а-яёа-z]+', raw_text)
raw_freq = Counter(raw_words)

wc_raw = WordCloud(
    width=800,
    height=400,
    background_color='white',
    colormap='viridis'
).generate_from_frequencies(raw_freq)

plt.figure(figsize=(12, 6))
plt.imshow(wc_raw, interpolation='bilinear')
plt.axis('off')
plt.title('Облако слов до обработки', fontsize=16)
plt.savefig('../wordcloud_before.png', dpi=150, bbox_inches='tight')
plt.show()
```



```
stats = {
    'Метрика': [
        'Всего документов',
        'Слов до обработки (всего)',
        'Уникальных слов до обработки',
        'Слов после обработки (всего)',
        'Уникальных лемм после обработки',
        'Сокращение словаря, %'
    ],
    'Значение': [
        len(texts),
        sum(len(text.split()) for text in texts),
        len(set(word.lower() for text in texts for word in text.split())),
        sum(len(lemmas) for lemmas in lemmas_all),
        len(set(lemma for doc in lemmas_all for lemma in doc)),
        round(
            (1 - len(set(lemma for doc in lemmas_all for lemma in doc)) /
             len(set(word.lower() for text in texts for word in text.split()))) * 100,
            2
        )
    ]
}
print(pd.DataFrame(stats).to_string(index=False))
```

```
                     Метрика  Значение
              Всего документов     15.00
    Слов до обработки (всего)    746.00
 Уникальных слов до обработки    589.00
 Слов после обработки (всего)    499.00
Уникальных лемм после обработки    424.00
          Сокращение словаря, %     28.01
```

Лаб 1

Предварительная обработка текстовых данных

4 ИВТ_ТИИ Клименко В.А.