# Лабораторная работа 5

## Клименко В.А.

#### Импорт и загрузка данных

```
import os
import json
import re
from pprint import pprint

import spacy
from spacy import displacy
import pandas as pd
from collections import defaultdict

# Настройка отображения
pd.set_option("display.max_colwidth", None)

texts_data = {}
gt_data = {}

news_dir = "./lab5_data/news/"
gt_path = "./lab5_data/ground_truth.json"

if os.path.exists(news_dir):
    for fname in sorted(os.listdir(news_dir)):
        if fname.endswith(".txt"):
            with open(
                os.path.join(news_dir, fname), "r", encoding="utf-8"
            ) as f:
                texts_data[fname] = f.read()

if os.path.exists(gt_path):
    with open(gt_path, "r", encoding="utf-8") as f:
        gt_data = json.load(f)

print(f"  Загружено {len(texts_data)} текстов.")
print("Пример ground truth для news_01.txt:")
pprint(gt_data['news_01.txt'], sort_dicts=True)
```

```
  Загружено 10 текстов.
Пример ground truth для news_01.txt:
{'DATE': ['15 октября 2023 года'],
 'LOC': ['Казани'],
 'MONEY': ['500 млн рублей'],
 'ORG': ['Яндекс'],
 'PER': ['Артем Иванов']}
```

**Подход 1: Регулярные выражения (Regex)**

```
def extract_with_regex(text):
    entities = {"DATE": [], "MONEY": []}

    date_pattern = r"\b\d{1,2}\s+[а-яА-ЯёЁ]+(?:\s+\d{4})?\b"
    money_pattern = r"\b\d+(?:[\.,]\d+)?\s*(?:млн|тыс|млрд)?\s*(?:рублей|рубля|руб|
долларов|доллара|евро|\$)\b"

    for match in re.finditer(date_pattern, text, re.IGNORECASE):
        entities["DATE"].append(match.group(0).strip())

    for match in re.finditer(money_pattern, text, re.IGNORECASE):
        entities["MONEY"].append(match.group(0).strip())

    return entities


# Проверка на первом тексте
test_text = texts_data["news_01.txt"]
print(f"Текст: {test_text[:100]}...")
print(f"Regex нашел: {extract_with_regex(test_text)}")
```

```
Текст: 15 октября 2023 года компания Яндекс официально открыла новый офис в Казани. Общие
инвестиции в прое...
Regex нашел: {'DATE': ['15 октября 2023'], 'MONEY': ['500 млн рублей']}
```

**Подход 2: Машинное обучение (spaCy)**

```
nlp = spacy.load("ru_core_news_sm")


def extract_with_spacy(text):
    entities = defaultdict(list)
    doc = nlp(text)
    for ent in doc.ents:
        entities[ent.label_].append(ent.text)
    return dict(entities)


# Проверка
print(f"spaCy нашел: {extract_with_spacy(test_text)}")

# ВАУ-ЭФФЕКТ: Визуализация
doc = nlp(test_text)
displacy.render(doc, style="ent", jupyter=True)
```

```
spaCy нашел: {'ORG': ['Яндекс'], 'LOC': ['Казани'], 'PER': ['Артем Иванов']}
```

15 октября 2023 года компания Яндекс ORG официально открыла новый офис в Казани LOC . Общие инвестиции в проект составили 500 млн рублей. Генеральный директор Артем Иванов PER заявил, что это важный шаг для развития IT-сектора в регионах.

**Оценка качества (Метрики)**

```
def calculate_metrics(predicted, ground_truth):
    # Вспомогательная функция для нормализации текста сущностей
    def normalize(s):
        return s.lower().strip().rstrip(".,!?:;\"'«»")

    # Собираем все сущности из словарей в единые множества (упрощенно по всем типам сразу)
    pred_set = set()
    for ent_list in predicted.values():
        for ent in ent_list:
            pred_set.add(normalize(ent))

    gt_set = set()
    for ent_list in ground_truth.values():
        for ent in ent_list:
            gt_set.add(normalize(ent))

    # Пересечение (найденное верное)
    intersection = pred_set.intersection(gt_set)

    precision = len(intersection) / len(pred_set) if len(pred_set) > 0 else 0.0
    recall = len(intersection) / len(gt_set) if len(gt_set) > 0 else 0.0
    f1 = (
```

```
        (2 * precision * recall) / (precision + recall)
        if (precision + recall) > 0
        else 0.0
    )

    return round(precision, 3), round(recall, 3), round(f1, 3)


# Сравнение на всех текстах
results = []
for fname in texts_data.keys():
    text = texts_data[fname]
    gt = gt_data[fname]
    pred_regex = extract_with_regex(text)
    pred_spacy = extract_with_spacy(text)
    # Считаем метрики (упрощенно, по всем типам сущностей сразу)
    p_reg, r_reg, f1_reg = calculate_metrics(pred_regex, gt)
    p_spc, r_spc, f1_spc = calculate_metrics(pred_spacy, gt)

    results.append(
        {
            "Файл": fname,
            "Regex_P": p_reg,
            "Regex_R": r_reg,
            "Regex_F1": f1_reg,
            "spaCy_P": p_spc,
            "spaCy_R": r_spc,
            "spaCy_F1": f1_spc,
        }
    )
print("  СРАВНЕНИЕ МЕТОДОВ:")
df_results = pd.DataFrame(results)
display(df_results)
```

```
  СРАВНЕНИЕ МЕТОДОВ:
```

| | Файл | Regex_P | Regex_R | Regex_F1 | spaCy_P | spaCy_R | spaCy_F1 |
|---|---|---|---|---|---|---|---|
| 0 | news_01.txt | 0.500 | 0.200 | 0.286 | 1.000 | 0.600 | 0.750 |
| 1 | news_02.txt | 0.500 | 0.200 | 0.286 | 0.800 | 0.800 | 0.800 |
| 2 | news_03.txt | 1.000 | 0.167 | 0.286 | 0.800 | 0.667 | 0.727 |
| 3 | news_04.txt | 0.667 | 0.333 | 0.444 | 1.000 | 0.500 | 0.667 |
| 4 | news_05.txt | 0.500 | 0.200 | 0.286 | 0.333 | 0.200 | 0.250 |
| 5 | news_06.txt | 0.500 | 0.143 | 0.222 | 0.857 | 0.857 | 0.857 |
| 6 | news_07.txt | 0.000 | 0.000 | 0.000 | 0.800 | 0.800 | 0.800 |
| 7 | news_08.txt | 0.000 | 0.000 | 0.000 | 1.000 | 0.750 | 0.857 |
| 8 | news_09.txt | 1.000 | 0.400 | 0.571 | 0.750 | 0.600 | 0.667 |
| 9 | news_10.txt | 1.000 | 0.200 | 0.333 | 1.000 | 0.800 | 0.889 |

**Анализ ошибок (Самое важное!)**

```
print("  АНАЛИЗ ОШИБОК:")

# Найдите текст, где Regex нашел дату неправильно (например, "5 ноября" контексте спорта),
или где spaCy не нашел организацию


def get_normalized_set(ent_dict):
    return {
        ent.lower().strip().rstrip(".,!?:;\"'«»")
        for ent_list in ent_dict.values()
        for ent in ent_list
    }


for fname in list(texts_data.keys())[:5]:  # Просмотрим первые 5 файлов
    text = texts_data[fname]
    gt = gt_data[fname]
    pred_regex = extract_with_regex(text)
    pred_spacy = extract_with_spacy(text)

    gt_set = get_normalized_set(gt)
    reg_set = get_normalized_set(pred_regex)
    spc_set = get_normalized_set(pred_spacy)

    print(f"═══ Файл: {fname} ═══")
    print(f"Текст: {text}")

    print("Эталон (GT): ", end="")
    pprint(gt, sort_dicts=True)

    print(f"Нашел Regex: ", end="")
    pprint(pred_regex, sort_dicts=True)

    print(f"Нашел spaCy: ", end="")
    pprint(pred_spacy, sort_dicts=True)

    print(f"\t→ Regex пропустил (но нашел spaCy): {gt_set.intersection(spc_set) -
reg_set}")
    print(f"\t→ spaCy пропустил (но нашел Regex): {gt_set.intersection(reg_set) -
spc_set}")
    print(f"\t→ Ложные срабатывания Regex (нет в GT): {reg_set - gt_set}")
    print(f"\t→ Ложные срабатывания spaCy (нет в GT): {spc_set - gt_set}")
    print()
```

```
  АНАЛИЗ ОШИБОК:
═══ Файл: news_01.txt ═══
Текст: 15 октября 2023 года компания Яндекс официально открыла новый офис в Казани. Общие
```

```
инвестиции в проект составили 500 млн рублей. Генеральный директор Артем Иванов заявил, что
это важный шаг для развития IT-сектора в регионах.
Эталон (GT): {'DATE': ['15 октября 2023 года'],
 'LOC': ['Казани'],
 'MONEY': ['500 млн рублей'],
 'ORG': ['Яндекс'],
 'PER': ['Артем Иванов']}
Нашел Regex: {'DATE': ['15 октября 2023'], 'MONEY': ['500 млн рублей']}
Нашел spaCy: {'LOC': ['Казани'], 'ORG': ['Яндекс'], 'PER': ['Артем Иванов']}
        → Regex пропустил (но нашел spaCy): {'казани', 'артем иванов', 'яндекс'}
        → spaCy пропустил (но нашел Regex): {'500 млн рублей'}
        → Ложные срабатывания Regex (нет в GT): {'15 октября 2023'}
        → Ложные срабатывания spaCy (нет в GT): set()

=== Файл: news_02.txt ===
Текст: Вчера, 12 сентября, президент России Владимир Путин провел встречу с главой
Сбербанка Германом Грефом в Москве. Обсуждались вопросы цифровизации экономики. Встреча
длилась около 2 часов.
Эталон (GT): {'DATE': ['12 сентября'],
 'LOC': ['Москве'],
 'ORG': ['Сбербанка'],
 'PER': ['Владимир Путин', 'Германом Грефом']}
Нашел Regex: {'DATE': ['12 сентября', '2 часов'], 'MONEY': []}
Нашел spaCy: {'LOC': ['России', 'Москве'],
 'ORG': ['Сбербанка'],
 'PER': ['Владимир Путин', 'Германом Грефом']}
        → Regex пропустил (но нашел spaCy): {'германом грефом', 'владимир путин',
'москве', 'сбербанка'}
        → spaCy пропустил (но нашел Regex): {'12 сентября'}
        → Ложные срабатывания Regex (нет в GT): {'2 часов'}
        → Ложные срабатывания spaCy (нет в GT): {'россии'}

=== Файл: news_03.txt ===
Текст: Акции компании Apple (AAPL) выросли на 5% после презентации iPhone 15. Тим Кук
выступил в Купертино, Калифорния. Аналитики Goldman Sachs прогнозируют рост до 200 долларов
за акцию к концу года.
Эталон (GT): {'LOC': ['Купертино', 'Калифорния'],
 'MONEY': ['200 долларов'],
 'ORG': ['Apple', 'Goldman Sachs'],
 'PER': ['Тим Кук']}
Нашел Regex: {'DATE': [], 'MONEY': ['200 долларов']}
Нашел spaCy: {'LOC': ['Купертино', 'Калифорния'],
 'ORG': ['Apple (AAPL)', 'Goldman Sachs'],
 'PER': ['Тим Кук']}
        → Regex пропустил (но нашел spaCy): {'купертино', 'калифорния', 'goldman sachs',
'тим кук'}
        → spaCy пропустил (но нашел Regex): {'200 долларов'}
        → Ложные срабатывания Regex (нет в GT): set()
        → Ложные срабатывания spaCy (нет в GT): {'apple (aapl)'}

=== Файл: news_04.txt ===
Текст: Известный актер Брэд Питт посетил премьеру своего нового фильма в Лос-Анджелесе.
```

```
Мероприятие состоялось 25 августа. Билеты стоили от 50 до 150 долларов. Организатором
выступила компания Warner Bros.
Эталон (GT): {'DATE': ['25 августа'],
 'LOC': ['Лос-Анджелесе'],
 'MONEY': ['50', '150 долларов'],
 'ORG': ['Warner Bros.'],
 'PER': ['Брэд Питт']}
Нашел Regex: {'DATE': ['25 августа', '50 до'], 'MONEY': ['150 долларов']}
Нашел spaCy: {'LOC': ['Лос-Анджелесе'], 'ORG': ['Warner Bros'], 'PER': ['Брэд Питт']}
        → Regex пропустил (но нашел spaCy): {'warner bros', 'лос-анджелесе', 'брэд питт'}
        → spaCy пропустил (но нашел Regex): {'150 долларов', '25 августа'}
        → Ложные срабатывания Regex (нет в GT): {'50 до'}
        → Ложные срабатывания spaCy (нет в GT): set()

═══ Файл: news_05.txt ═══
Текст: Ученые из МГУ имени Ломоносова опубликовали статью в журнале Nature. Исследование
проводилось в лаборатории под руководством профессора Петрова И.И. Грант на сумму 2 млн
рублей был выделен в 2022 году.
Эталон (GT): {'DATE': ['2022 году'],
 'MONEY': ['2 млн рублей'],
 'ORG': ['МГУ', 'Nature'],
 'PER': ['Петрова И.И.']}
Нашел Regex: {'DATE': ['2 млн'], 'MONEY': ['2 млн рублей']}
Нашел spaCy: {'ORG': ['МГУ имени Ломоносова', 'Nature'], 'PER': ['Петрова И.И. Грант']}
        → Regex пропустил (но нашел spaCy): {'nature'}
        → spaCy пропустил (но нашел Regex): {'2 млн рублей'}
        → Ложные срабатывания Regex (нет в GT): {'2 млн'}
        → Ложные срабатывания spaCy (нет в GT): {'мгу имени ломоносова', 'петрова и.и.
грант'}
```

**Итоговые выводы**

```
print("Какой метод (Regex или spaCy) показал более высокий F1-score?")
display(df_results.style.highlight_max(axis=1, subset=["Regex_F1", "spaCy_F1"],
color="green"))

print("Почему Regex плохо справляется с извлечением имен (PER) и организаций (ORG)?")
print(
    """
    Имена и организации не имеют жесткой символьной структуры:
    могут состоять из любых слов, склоняться по падежам
    и совпадать с обычными существительными.
    """
)

print("Приведите пример, где spaCy ошибся (ложноположительное срабатывание). Почему?")
print(
    """
    spaCy может ошибочно выделить слово с заглавной буквы в начале предложения
    или название в кавычках как организацию (ORG) или персону (PER), либо захватить
соседнее слово,
    потому что модель опирается на статистические паттерны контекста и регистр букв.
    """
)

print("В каких реальных задачах лучше использовать Regex, а в каких ML?")
print(
    """
    Regex лучше использовать для сущностей со строгим форматом:
    даты,суммы денег, номера телефонов, email и т.д.
    ML необходим для извлечения смысловых и контекстно-зависимых сущностей в свободном
тексте:
    названия компаний, географические объекты, должности.
    """
)
```

```
Какой метод (Regex или spaCy) показал более высокий F1-score?
```

| | Файл | Regex_P | Regex_R | Regex_F1 | spaCy_P | spaCy_R | spaCy_F1 |
|---|---|---|---|---|---|---|---|
| **0** | news_01.txt | 0.500000 | 0.200000 | 0.286000 | 1.000000 | 0.600000 | 0.750000 |
| **1** | news_02.txt | 0.500000 | 0.200000 | 0.286000 | 0.800000 | 0.800000 | 0.800000 |
| **2** | news_03.txt | 1.000000 | 0.167000 | 0.286000 | 0.800000 | 0.667000 | 0.727000 |
| **3** | news_04.txt | 0.667000 | 0.333000 | 0.444000 | 1.000000 | 0.500000 | 0.667000 |
| **4** | news_05.txt | 0.500000 | 0.200000 | 0.286000 | 0.333000 | 0.200000 | 0.250000 |
| **5** | news_06.txt | 0.500000 | 0.143000 | 0.222000 | 0.857000 | 0.857000 | 0.857000 |
| **6** | news_07.txt | 0.000000 | 0.000000 | 0.000000 | 0.800000 | 0.800000 | 0.800000 |
| **7** | news_08.txt | 0.000000 | 0.000000 | 0.000000 | 1.000000 | 0.750000 | 0.857000 |

| | Файл | Regex_P | Regex_R | Regex_F1 | spaCy_P | spaCy_R | spaCy_F1 |
|---|---|---|---|---|---|---|---|
| **8** | news_09.txt | 1.000000 | 0.400000 | 0.571000 | 0.750000 | 0.600000 | 0.667000 |
| **9** | news_10.txt | 1.000000 | 0.200000 | 0.333000 | 1.000000 | 0.800000 | 0.889000 |

```
Почему Regex плохо справляется с извлечением имен (PER) и организаций (ORG)?

    Имена и организации не имеют жесткой символьной структуры:
    могут состоять из любых слов, склоняться по падежам
    и совпадать с обычными существительными.

Приведите пример, где spaCy ошибся (ложноположительное срабатывание). Почему?

    spaCy может ошибочно выделить слово с заглавной буквы в начале предложения
    или название в кавычках как организацию (ORG) или персону (PER),
    либо захватить соседнее слово/знак препинания,
    поскольку модель опирается на статистические паттерны контекста и регистр букв.

В каких реальных задачах лучше использовать Regex, а в каких ML?

    Regex лучше использовать для сущностей со строгим форматом:
    даты,суммы денег, номера телефонов, email и т.д.
    ML необходим для извлечения смысловых и контекстно-зависимых сущностей в свободном
тексте:
    названия компаний, географические объекты, должности.
```